

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{array}{l} \phi(x+y)=\phi(x)+\phi(y)\\ \phi(\lambda x)=\lambda \phi(x) \end{array}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x+\varphi y)=\lambda \phi(x)+\varphi \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 φ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x)=\phi(y)$ ，那么 $x=y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



- 2. 函数 ϕ 是满射（Surjective）：也就是满足等式 $\phi(V)=W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构 (Isomorphism)：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态 (Endomorphism)：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构 (Automorphism)：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的情况下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^{mn} 长度是 mn 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1, \cdots, b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变

之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

$$\end{array} \right] \right] \\ \$\$$$

基于它们各自的标准基 \mathcal{B} 和 \mathcal{C} ，它的变换矩阵是：

$$\begin{array}{l} 1 \text{ \& } 2 \text{ \& } 0 \\\ -1 \text{ \& } 1 \text{ \& } 3 \\\ 3 \text{ \& } 7 \text{ \& } 1 \\\ -1 \text{ \& } 2 \text{ \& } 4 \end{array}$$

那么现在，我们来看一下，基 B 和 C 改变为 \widetilde{B} 和 \widetilde{C} 之后，会有怎样的变化。

```


$$\begin{aligned} & \mathbb{S} \mathbb{S} \widetilde{\text{widelatide}}\{B\} = \text{left} \backslash \left[ \text{left} \begin{array}{l} \{ \} \end{array} \right] \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{right} \backslash \backslash \widetilde{\text{widelatide}}\{C\} = \text{left} \backslash \left[ \text{left} \begin{array}{l} \{ \} \end{array} \right] \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{array\} \backslash \text{right} \backslash \text{right} \backslash \mathbb{S} \mathbb{S} \end{aligned}$$


```

对于新基 $\{\widetilde{B}\}$ 和 $\{\widetilde{C}\}$, 我们得到 SS 和 TS :

```

$$$=\left[\begin{array}{l} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{array}\right], T=\left[\begin{array}{l} 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{array}\right]

```

于是，我们就可以通过公式得到想要的 \tilde{A}_{ϕ} 了。

$$S\tilde{S}\{A\}_{-1}\phi = T^{\wedge-1}A_{-1}\phi \quad S = \left[\begin{array}{ccc} 4 & -4 & -2 \\ 6 & 0 & 0 \\ 4 & 8 & 4 \\ 1 & 6 & 3 \end{array} \right]$$

两个重要的子空间

最后，我再来讲两个重要的子空间——核空间和像空间，说它们重要是有原因的。核空间可以帮助我们研究线性方程组的性质，同时还可以帮助我们吧复杂问题简化，也就是将复杂的大集合分解成小集合的并来研究。而像空间可以帮助我们快速得到线性方程组的秩，这样就能快速判断线性方程组解的情况。现在我们来具体了解一下。


核空间

核空间也叫零空间，你还记得 $Ax=b$ 吗？核空间关注的就是 $Ax=0$ ，也就是向量空间 V 中所有经过 ϕ 映射为零的向量集合，用符号表示就是： $\operatorname{ker}(\phi)$ 。核的维数叫做零化度（nullity），表示成： $\dim(\operatorname{ker}(\phi))$ 。

像空间

向量空间 V 中所有经过 ϕ 映射后的向量集合，叫做像空间，用符号表示就是： $\text{Im}(\phi)$ ，像空间维数就是秩，表示成： $\text{rk}(\phi)$ 。

通过图形表达出来，你应该能够更好地理解。



最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

```

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

```

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 $\mathbf{S1}$ 到 \mathbf{Sn} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{Sy}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

```

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

```

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```


理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1, \cdots, b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{aligned} \Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


- 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

```

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

```

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是 $(2,2)$ ，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了 $(1.09,0.72)$ ，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```

\begin{array}{l}
\Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\
\Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\
\Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4
\end{array}

```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```


\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}

```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是 $(2,2)$ ，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了 $(1.09,0.72)$ ，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```


$$\begin{cases} \Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\ \Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4 \end{cases}$$


```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```



$$\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```


理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 mn ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1, \cdots, b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是 $(2,2)$ ，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了 $(1.09,0.72)$ ，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 $\mathbf{\Phi}$ 就是 SVS 到 SWS 的线性映射： $\mathbf{\Phi}(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 $\mathbf{\Phi}$ 中的 \mathbf{j} 是从 1 到 n ，于是，我们就能得到一个 $\mathbf{\Phi}$ 的 $m\times n$ 的变换矩阵 $\mathbf{A}_{\mathbf{\Phi}}$ ，这个变换矩阵中的元素是 $\mathbf{A}_{\mathbf{\Phi}}(i,j)=\alpha_{ij}$ ，也就是说， $\mathbf{\Phi}(\mathbf{b}_j)$ 的坐标就是 $\mathbf{A}_{\mathbf{\Phi}}$ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_{\mathbf{\Phi}}(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 $\mathbf{\Phi}$ 表示成以下形式。

```


$$\begin{aligned} \mathbf{\Phi}(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \mathbf{\Phi}(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \mathbf{\Phi}(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4 \end{aligned}$$


```


于是，我们可以通过这些条件得到变换矩阵 $\mathbf{A}_{\mathbf{\Phi}}$ 如下。

```



$$\mathbf{A}_{\mathbf{\Phi}} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$


```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变

之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

$$\end{array} \right] \right] \\ \$\$$$

基于它们各自的标准基 \mathcal{B} 和 \mathcal{C} ，它的变换矩阵是：

$$\begin{array}{l} 1 \text{ \& } 2 \text{ \& } 0 \\\ -1 \text{ \& } 1 \text{ \& } 3 \\\ 3 \text{ \& } 7 \text{ \& } 1 \\\ -1 \text{ \& } 2 \text{ \& } 4 \end{array}$$

那么现在，我们来看一下，基 B 和 C 改变为 \widetilde{B} 和 \widetilde{C} 之后，会有怎样的变化。

```


$$\begin{aligned} & \mathbb{S} \mathbb{S} \widetilde{\text{widelatide}}\{B\} = \text{left} \backslash \left[ \text{left} \begin{array}{l} \{ \} \end{array} \right] \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{right} \backslash \backslash \widetilde{\text{widelatide}}\{C\} = \text{left} \backslash \left[ \text{left} \begin{array}{l} \{ \} \end{array} \right] \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{left} \begin{array}{l} \{ \} \end{array} \\ & \quad 1 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 0 \quad \backslash \backslash \backslash \\ & \quad 1 \\ & \backslash \text{end} \{ \text{array} \} \backslash \text{right} \backslash \text{right} \backslash \mathbb{S} \mathbb{S} \end{aligned}$$


```

对于新基 $\{\widetilde{B}\}$ 和 $\{\widetilde{C}\}$, 我们得到 SS 和 TS :

```

$$$=\left[\begin{array}{l} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{array}\right], T=\left[\begin{array}{l} 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{array}\right]

```

于是，我们就可以通过公式得到想要的 \tilde{A}_{ϕ} 了。

$$S\tilde{S}|_{\phi} = T^{-1} A_{\phi} S = \begin{pmatrix} 4 & -4 & -2 \\ 6 & 0 & 0 \\ 4 & 8 & 4 \\ 1 & 6 & 3 \end{pmatrix}$$

两个重要的子空间

最后，我再来讲两个重要的子空间——核空间和像空间，说它们重要是有原因的。核空间可以帮助我们研究线性方程组的性质，同时还可以帮助我们吧复杂问题简化，也就是将复杂的大集合分解成小集合的并来研究。而像空间可以帮助我们快速得到线性方程组的秩，这样就能快速判断线性方程组解的情况。现在我们来具体了解一下。


核空间

核空间也叫零空间，你还记得 $Ax=b$ 吗？核空间关注的就是 $Ax=0$ ，也就是向量空间 V 中所有经过 ϕ 映射为零的向量集合，用符号表示就是： $\operatorname{ker}(\phi)$ 。核的维数叫做零化度（nullity），表示成： $\dim(\operatorname{ker}(\phi))$ 。

像空间

向量空间 V_S 中所有经过 ϕ 映射后的向量集合，叫做像空间，用符号表示就是： $\text{Im}(\phi)$ ，像空间维数就是秩，表示成： $\text{rk}(\phi)$ 。

通过图形表达出来，你应该能够更好地理解。



最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解决问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间 V 和 W ，有一个函数 ϕ 来完成向量空间 V 到 W 的映射，如果我们想要同时保持向量空间结构不变，那么 ϕ 就要满足：

```

$$\begin{aligned} \phi(x+y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda \phi(x) \end{aligned}$$

```

其中，所有 x 和 y 属于向量空间 V ， λ 属于实数。于是，我们得到了线性映射的定义。

线性映射定义

假设有两个向量空间 V 和 W ， ϕ 是一个函数，它完成了向量空间 V 到 W 的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \mu y) = \lambda \phi(x) + \mu \phi(y)$$

其中，任意 x 和 y 都属于向量空间 V ，而任意 λ 和 μ 都属于实数。


当然，我们能将线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合 V 到 W 的三类特殊映射，了解一下函数 ϕ 在不一样的情况下究竟表达了怎样的关系。


1. 函数 ϕ 是单射（Injective）时：如果 $\phi(x) = \phi(y)$ ，那么 $x = y$ ，其中任意 x 和 y 都属于集合 V ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合 V 的一个元素唯一确定一个集合 W 的元素。



2. 函数 ϕ 是满射 (Surjective)：也就是满足等式 $\phi(V) = W$ ，从图中我们可以看出它表达的是多对一的关系，也就是多个集合 V 的元素能够确定一个集合 W 的元素。



3. 函数 ϕ 是双射 (Bijective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有 V 集合的元素都和 W 集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构（Isomorphism）：即函数 ϕ 使 V 到 W 是线性且双射的；
2. 自同态（Endomorphism）：即函数 ϕ 使 V 到 V 是线性的；
3. 自同构（Automorphism）：即函数 ϕ 使 V 到 V 是线性且双射的；
4. 把 V 到 V ，元素 x 到 x 的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们需要通过这些概念引出一个定理：有限维度的向量空间 V 和 W ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$ 矩阵向量空间，和 \mathbb{R}^n 长度是 m 的向量空间，我们可以认为它们是相同的，因为它们维度都是 m ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



线性映射的矩阵表示

刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个 n 维向量空间 V 和它的一个有序基 $B=(b_1,\cdots,b_n)$ ，那么对于任意一个属于 V 的 x ，我们能得到一个这样的线性组合： $x=\alpha_1 b_1+\cdots+\alpha_n b_n$ ，我们可以说

$$\alpha=\begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix}$$

是 x 的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系 SVS ，黄色是坐标系 SWS 。

在 SVS 中， \mathbf{e}_1 和 \mathbf{e}_2 是 SVS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{e}_1 和 \mathbf{e}_2 表示， \mathbf{x} 的坐标是(2,2)，于是， \mathbf{x} 在 SVS 中可以被表示成： $\mathbf{x}=2\mathbf{e}_1+2\mathbf{e}_2$ 。

在 SWS 中， \mathbf{b}_1 和 \mathbf{b}_2 是 SWS 的标准基，向量 \mathbf{x} 由线性组合 \mathbf{b}_1 和 \mathbf{b}_2 表示，而这里的 \mathbf{x} 坐标就不同了，变成了(1.09,0.72)，于是， \mathbf{x} 在 SWS 中可以被表示成： $\mathbf{x}=1.09\mathbf{b}_1+0.72\mathbf{b}_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间 SVS 和 SWS ，它们各自有相应的有序基 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_n)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_m)$ ，而 Φ 就是 SVS 到 SWS 的线性映射： $\Phi(\mathbf{b}_j)=\alpha_1\mathbf{c}_1+\cdots+\alpha_m\mathbf{c}_m$ 。

线性映射 Φ 中的 \mathbf{S} 是从 \mathbf{S} 到 \mathbf{S} ，于是，我们就能得到一个 Φ 的 $m\times n$ 的变换矩阵 \mathbf{A}_Φ ，这个变换矩阵中的元素是 $\mathbf{A}_\Phi(i,j)=\alpha_{ij}$ ，也就是说， $\Phi(\mathbf{b}_j)$ 的坐标就是 \mathbf{A}_Φ 的第 j 列。

我们可以来简化一下表达，把它表示成这样： $\mathbf{y}=\mathbf{A}_\Phi(\mathbf{x})$ 。其中， \mathbf{x} 是 SVS 基于 \mathbf{SB} 基的坐标向量， \mathbf{y} 是 SWS 基于 \mathbf{SC} 基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。

我们来看一个变换矩阵例子：已知两个向量空间 SVS 和 SWS ，它们各自相应的有序基是 $\mathbf{SB}=(\mathbf{b}_1,\cdots,\mathbf{b}_3)$ 和 $\mathbf{SC}=(\mathbf{c}_1,\cdots,\mathbf{c}_4)$ ，线性映射 Φ 表示成以下形式。

```

\begin{array}{l}
\Phi(\mathbf{b}_1)=\mathbf{c}_1-\mathbf{c}_2+3\mathbf{c}_3-\mathbf{c}_4 \\
\Phi(\mathbf{b}_2)=2\mathbf{c}_1+\mathbf{c}_2+7\mathbf{c}_3+2\mathbf{c}_4 \\
\Phi(\mathbf{b}_3)=3\mathbf{c}_2+\mathbf{c}_3+4\mathbf{c}_4
\end{array}

```


于是，我们可以通过这些条件得到变换矩阵 \mathbf{A}_Φ 如下。

```


\mathbf{A}_\Phi=\begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}

```

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



原数据



旋转45度



沿平行

第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过45度变换后得到的，它的变换矩阵是下面这样的。

```
SSA_{1}=\left[\begin{array}{cc}\cos \left(\frac{\pi}{4}\right) & -\sin \left(\frac{\pi}{4}\right) \\\sin \left(\frac{\pi}{4}\right) & \cos \left(\frac{\pi}{4}\right)\end{array}\right]SS
```

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

```
SSA_{2}=\left[\begin{array}{cc}2 & 0 \\0 & 1\end{array}\right]SS
```

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

基的改变


之前我们讨论的线性映射都是在基是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。

现在我们就来看看，如果我们改变向量空间 VS 和 WS 的基，线性映射 Φ 的变换矩阵会如何改变。我们给向量空间 VS 和 WS 各自增加两个有序基： $\widetilde{B}=\left\{\widetilde{b}_{1}, \ldots, \widetilde{b}_{n}\right\}$ 和 $\widetilde{C}=\left\{\widetilde{c}_{1}, \ldots, \widetilde{c}_{m}\right\}$ ，而 \widetilde{A}_{Φ} 是基于新的有序基的变换矩阵。这样， \widetilde{A}_{Φ} 变换矩阵的计算公式就是： $\widetilde{A}_{\Phi}=T^{-1} A_{\Phi} S$ 。

在这个新的公式中， S 是 $\mathbb{R}^{n \times n}$ 向量空间 VS 的恒等映射变换矩阵，向量空间 VS 的恒等映射把基于 \widetilde{B} 的坐标，映射到基于 B 的坐标上。同理， T 是 $\mathbb{R}^{m \times m}$ 向量空间 WS 的恒等映射变换矩阵，向量空间 WS 的恒等映射把基于 \widetilde{C} 的坐标，映射到基于 C 的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射 Φ 的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间 \mathbb{R}^3 到四维实数向量空间 \mathbb{R}^4 的一个线性映射，它们各自有标准基 B 和 C 。

```
SB=\left[\begin{array}{l}1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1\end{array}\right], C=\left[\begin{array}{l}1 \\0 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\1 \\0 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\1 \\0\end{array}\right],\left[\begin{array}{l}0 \\0 \\0 \\1\end{array}\right]
```

最后我以一个定理来结束本节的内容，秩-零化度定理： $\dim(V) = \dim(\ker(\phi)) + \dim(\text{im}(\phi))$ 。

本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来回答问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。